

# Информационный поиск



Лекция 2



# Булев поиск

Используются операторы алгебры логики (or, and, xor). Есть только два варианта: объект либо подходит под запрос, либо нет.

Кошка была злая и вредная, но мы ее все равно любили. Звали ее Кусей, и была она рыжая в черную полоску.

Кошка - домашнее животное, одно из наиболее популярных (наряду с собакой) «животных-компаньонов»

Домашнее животное - важная часть жизни ребенка, так как это учит его ответственности.

“домашнее животное”  
AND  
“кошка”

Кошка - домашнее животное, одно из наиболее популярных (наряду с собакой) «животных-компаньонов»

# Поиск по сходству (нечёткий поиск)

Надстройка над булевым поиском: допускаются отклонения от запроса.

Кошка была злая и вредная, но мы ее все равно любили. Звали ее Кусей, и была она рыжая в черную полоску.

Кошки - очень хитрые и опасные хищники, которые, несмотря на свои малые размеры, успешно охотятся на крупных птиц.

Я всегда много читал о кошках, у меня даже есть целая коллекция книг.

“кошка”

Кошка была злая и вредная...

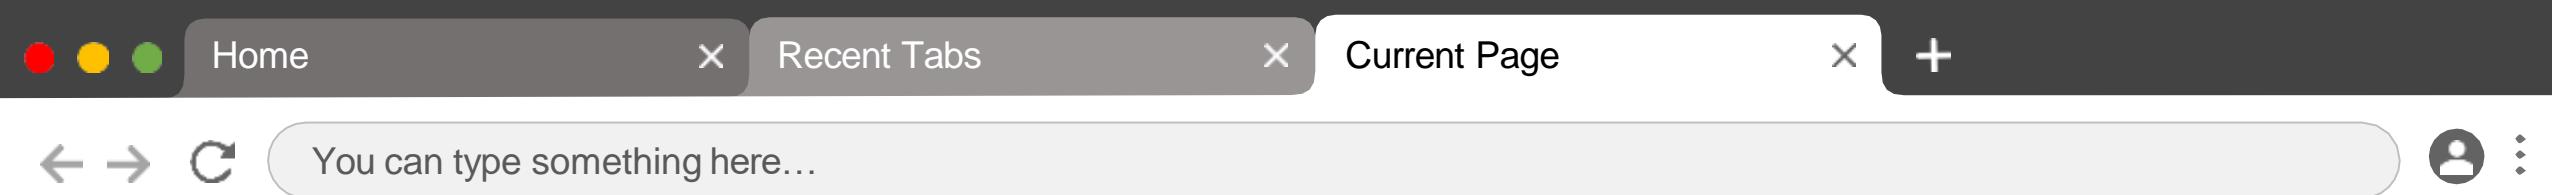
Кошки - очень хитрые и ...

Я всегда много читал о кошках...

# Поиск по сходству (нечёткий поиск)

Зачем нужен поиск по сходству?

- чтобы могли находиться похожие слова (например, формы одного слова)
- но, конечно, для этого лучше использовать нормализацию текста, об этом поговорим чуть позже
- для исправления опечаток



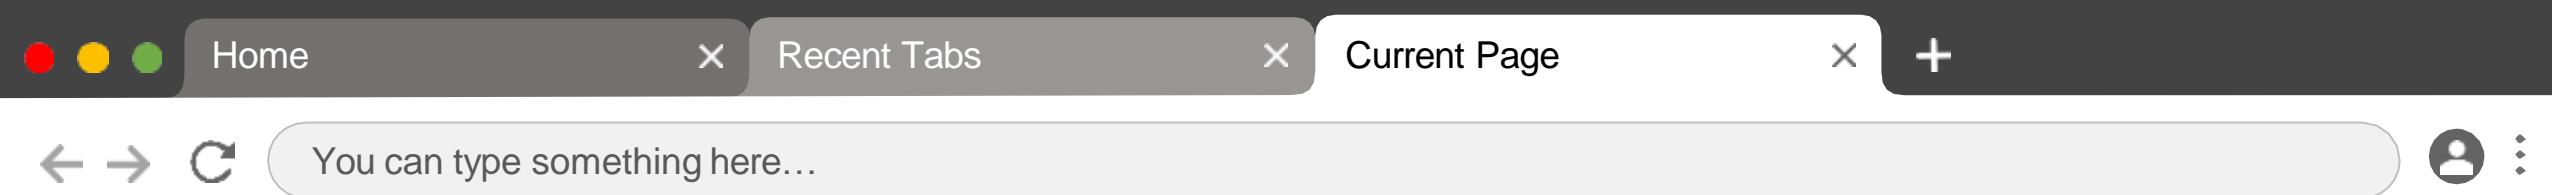
# Исправление опечаток

Реализация:

- исправление изолированного термина
  - расстояние редактирования
  - пересечение k-грамм
- исправление с учётом контекста
- фонетическое исправление

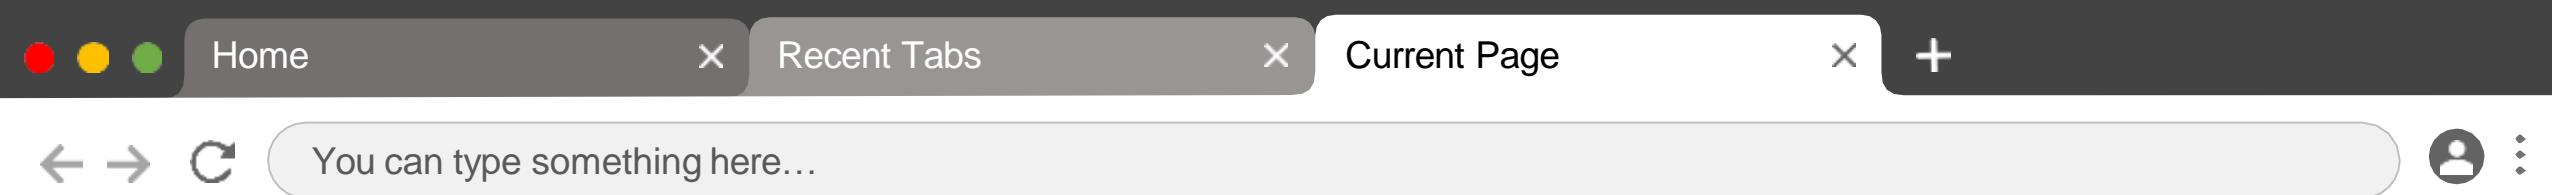
# Расстояние редактирования

- чаще всего – расстояние Левенштейна
- расстояние Левенштейна между двумя строками символов  $s_1$  и  $s_2$  — это минимальное количество операций редактирования, с помощью которых строку  $s_1$  можно трансформировать в строку  $s_2$
- операции редактирования, позволяющие это сделать, включают в себя следующие преобразования:
  - 1) вставка символа в строку
  - 2) удаление символа из строки
  - 3) замена символа в строке другим символом
- расстояние Дамерау-Левенштейна:
  - + 4) транспозиция символов



# Расстояние редактирования

- для слова с опечаткой ищем в словаре слово с минимальным расстоянием редактирования до него
- если таких слов несколько, выбираем более распространенный вариант (распространённость считаем либо по словарю, либо по запросам других пользователей)



# Расстояние редактирования

- вариантов слов с указанным расстоянием редактирования может быть много, перебор может оказаться ресурсозатратным
- существуют разные эвристики: например, считается, что люди почти никогда не опечатываются в первой букве слова, поэтому такие варианты исправлений можно не учитывать

You can type something here...



# Пересечение k-грамм

Фактически  $k$ -граммный индекс используется для поиска терминов лексикона, содержащих большое количество  $k$ -грамм, общих с запросом. Идея заключается в том, что при разумной трактовке выражения “большое количество общих  $k$ -грамм” процесс поиска по существу сводится к однократному просмотру “словопозиций”<sup>4</sup> для  $k$ -грамм, входящих в запрос  $q$ .

Например, на рис. 3.7 показана часть словопозиций для трех биграмм в запросе *bord*. Допустим, что мы желаем найти термины лексикона, содержащие по крайней мере две из этих трех биграмм. Однократное сканирование записей (как описано в главе 1) позволило бы перечислить все такие термины; в примере, показанном на рис. 3.7, перечислены термины *aboard*, *boardroom* и *border*.

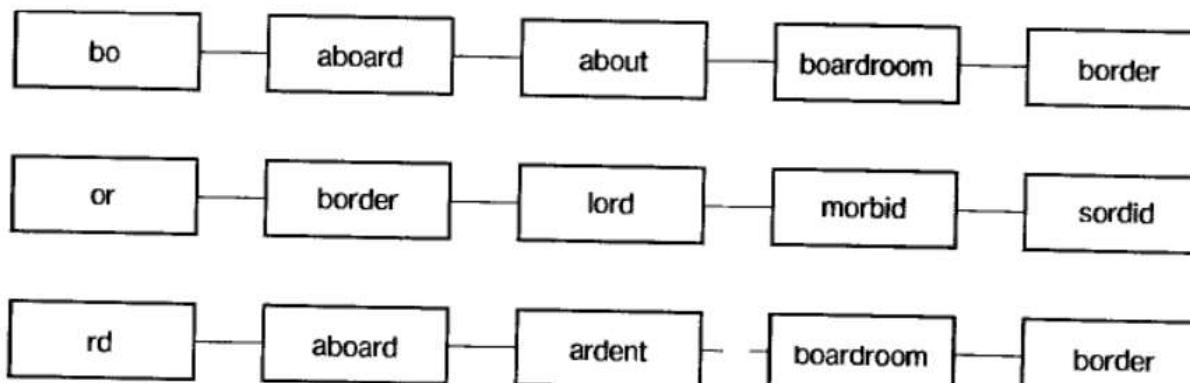
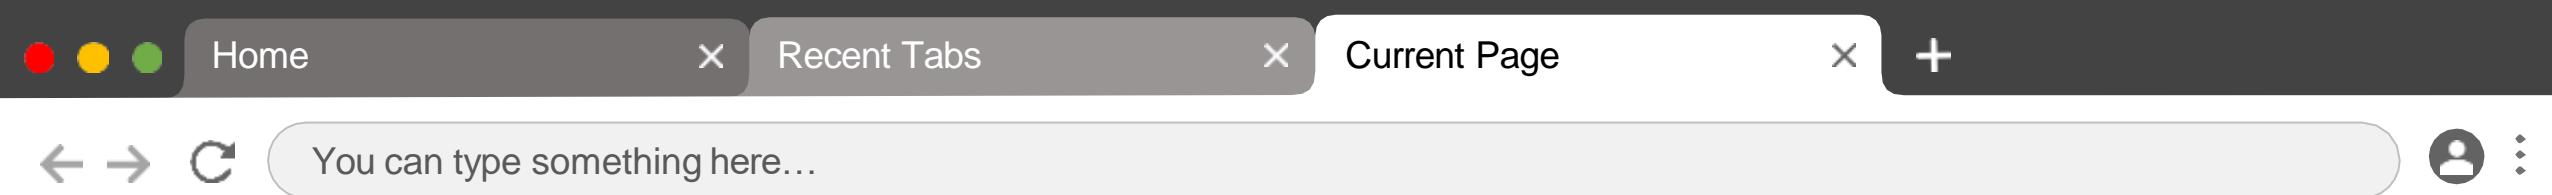


Рис. 3.7 Совпадение по крайней мере двух из трех биграмм в запросе *bord*



Home

Recent Tabs

Current Page

X

+

You can type something here...



⋮

# Исправление с учётом контекста

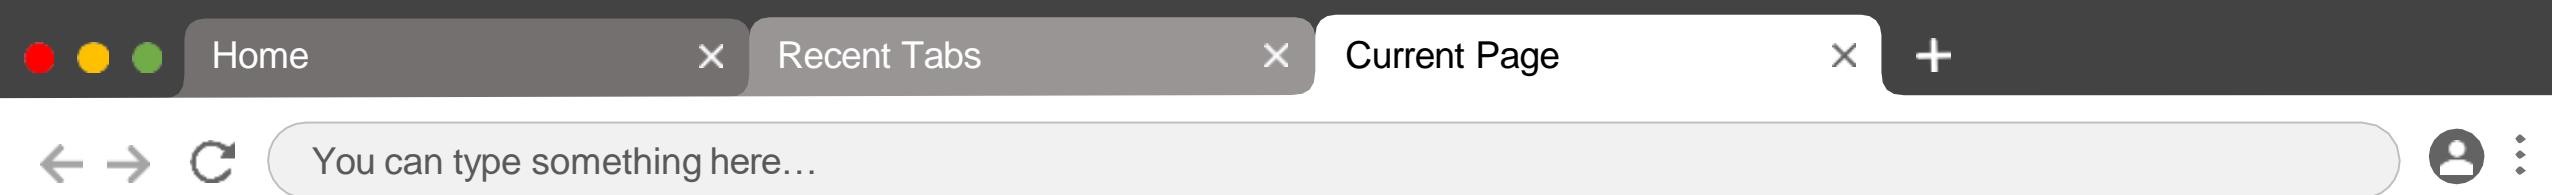
Допустим, опечатка в запросе привела к тому, что все слова в нём вроде бы существующие, но запрос получился бессмысленным. Например, «мальчик поел песню».

Если в ответ на фразу, подобную этой, будет возвращено лишь небольшое количество документов, то поисковая система может принять решение исправить этот запрос на «мальчик поет песню».

Простейший способ сделать это — перечислить исправления для каждого из трех терминов, даже если все термины запроса написаны правильно,

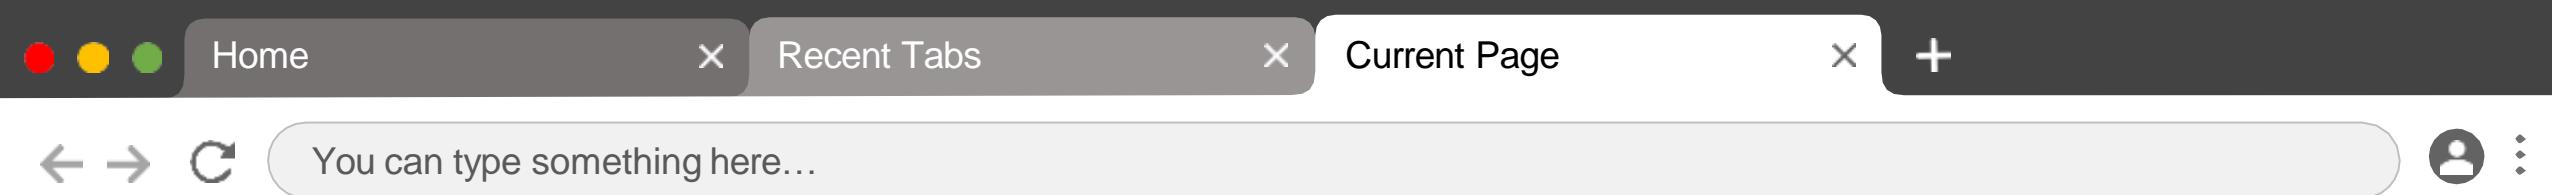
а затем попробовать произвести замену каждого термина фразы.

Более эффективный способ — перебирать только те комбинации возможных исправлений, которые чаще остальных встречаются в коллекции документов или в логах запросов.



# Фонетическое исправление

- **Soundex** и другие похожие алгоритмы
- Основаны на фонетическом хешировании – слова с похожим звучанием будут получать один и тот же хэш
- Для чего нужно фонетическое исправление?



# Нормализация текста

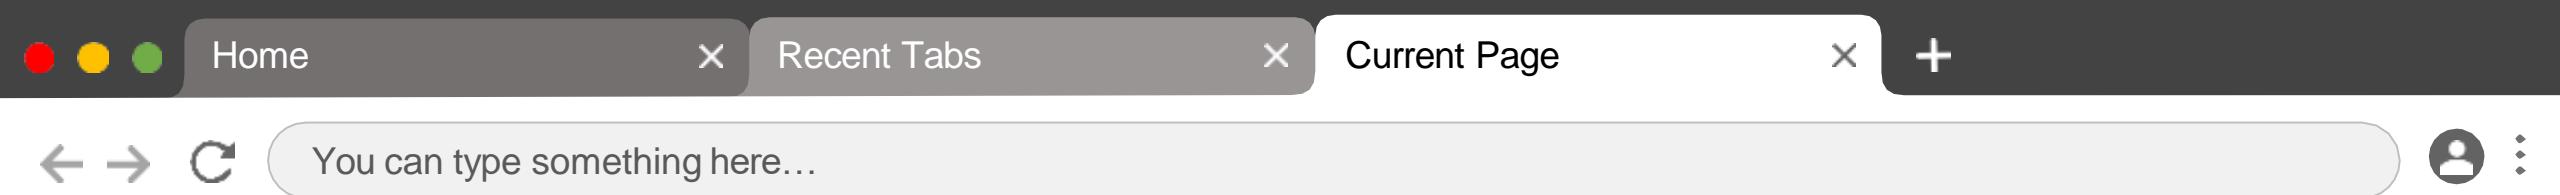
- приведение к единому регистру
- лемматизация / стемминг
- удаление стоп-слов (нужно ли?)

# Нормализация текста

- приведение к единому регистру
- лемматизация / стемминг
- удаление стоп-слов (нужно ли?)

Какие задачи решает?

- нахождение разных форм слов из запроса
- сжатие словаря



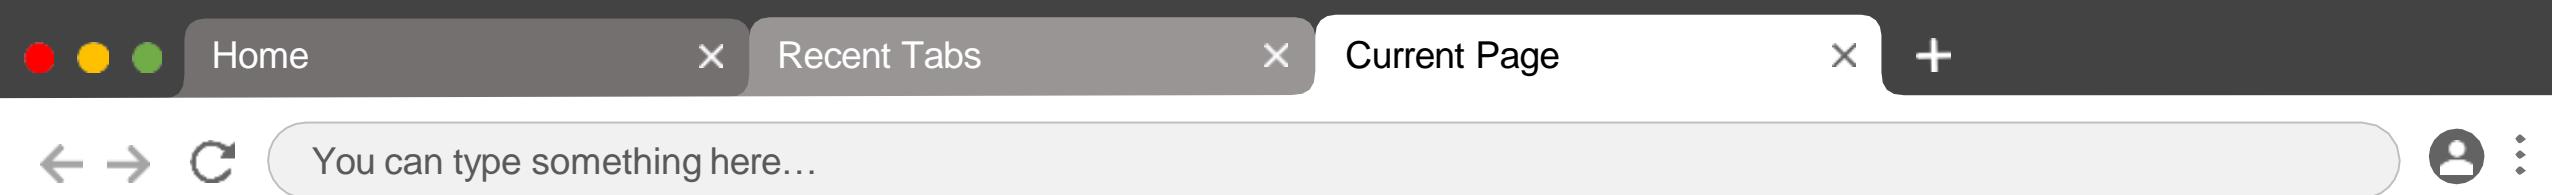
## Стемминг

Процесс приведения слов к их корневой форме путём удаления аффиксов, таких, как суффиксы и префиксы. Корневая форма не всегда может быть корректным словом в словаре, но она помогает стандартизировать варианты одного и того же слова.

## Лемматизация

Процесс приведения слов к их начальной форме (лемме), возвращает корректные слова из словаря.

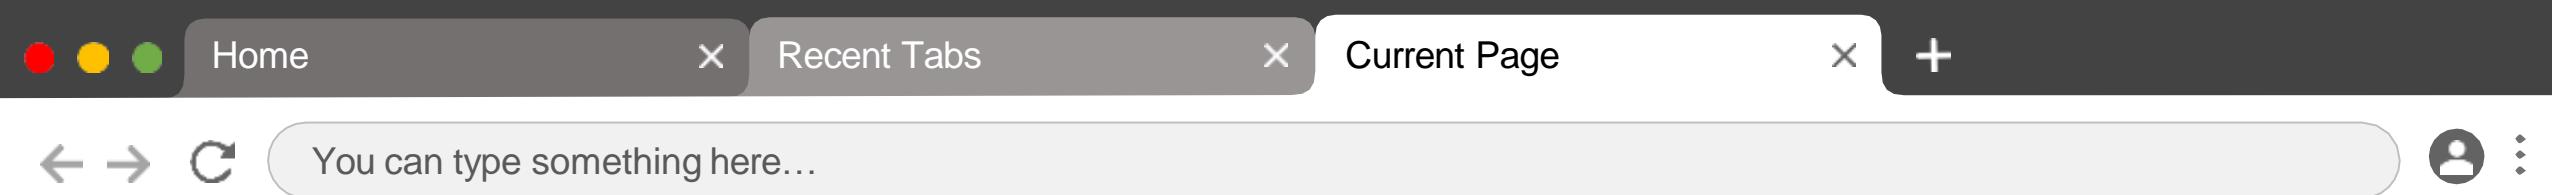
Что лучше?



# Стоп-слова

Стоп-слова – **это слова**, которые часто встречаются в тексте, но обычно не несут смысловой нагрузки.

- какие слова считать стоп-словами?
- какие слова могут считаться стоп-словами, скажем, для задачи частотного анализа, но не будут таковыми для задач информационного поиска?



# Что почитать?

- Статья на Хабре про нечёткий поиск: <https://habr.com/ru/articles/114997/>
- Учебник «Введение в информационный поиск» (Маннинг, Рагхаван, Шютце)